

Phát triển Chatbot và các hệ thống hỏi đáp với AI tạo sinh

Bài 2. Hiểu ngôn ngữ tự nhiên

PGS.TS. Lê Thanh Hương
Trường Công nghệ thông tin và Truyền thông
Đại Học Bách Khoa Hà Nội

1. Các bước hoạt động của chatbot
2. Nhận diện ý định
3. Nhận dạng thực thể
4. Phân tích cảm xúc trong hội thoại
5. Các kỹ thuật nâng cao chất lượng chatbot với LLM

1. Các bước hoạt động của chatbot

- Người dùng nhập câu hỏi
- Tiền xử lý câu hỏi: Xử lý lỗi chính tả, sai dấu, các từ viết tắt
- Hệ thống xác định mục đích hỏi (intent)
- Trích xuất các thông tin cần thiết (entity/slot)
- Xử lý và trả lời
- Ví dụ:
 - *Mình muốn đặt vé đi Hà Nội vào sáng mai*
 - **Intent:** Đặt vé máy bay
 - **Named Entities:** destination= Hà Nội, time = sáng mai
 - Hệ thống phân tích:
 - *Các chuyến bay đi Hà Nội vào sáng mai còn chỗ không?*
 - *Giá vé hiện tại là bao nhiêu?*
 - Trả lời:
 - *Bạn muốn đặt vé đi Hà Nội vào sáng mai phải không? Hiện có chuyến bay lúc 7:30 sáng với giá 1.200.000 VND. Bạn có muốn đặt luôn không?*

Ví dụ

Chatbot cho Quán cà phê

Product : Product name, size, giá, topping

User: name, address, order

User: Cho tôi 1 capuchino size M, 1 trà đào cam sả size M.
Tổng tiền bao nhiêu bạn?

- Intent: order, how much_price

Bot: Cảm ơn bạn, tôi đã nhận đơn. Của bạn hết 100k. Cho tôi địa chỉ ship hàng nhé?

User: 12 phố Bạch Mai

- Intent: giveInfo_address

2. Nhận diện ý định (intent detection)

- Vai trò:
 - Hiểu yêu cầu của người dùng
 - Điều hướng chatbot đến chức năng phù hợp
- Ví dụ:
 - *Tôi muốn đặt vé đi Đà Nẵng* → Đặt vé
 - *Hôm nay ở Hà Nội có mưa không?* → Tra cứu thời tiết
 - *Tại sao cần sử dụng RAG trong xây dựng chatbot với GenAI?* → why
 - *Làm cách nào để áp dụng RAG hiệu quả trong xây dựng chatbot với GenAI?* → how

Các loại Intent phổ biến

- Chào hỏi
- Đặt lịch hẹn
- Yêu cầu thông tin
 - What/ why/ who/ when/ how/ how many/ yesno, ...
- Khen/chê
- Khiếu nại
- Kết thúc cuộc trò chuyện

Các phương pháp Intent Detection

- Dựa trên luật
- Dựa trên học máy
- Dựa trên học sâu

Rule-based Intent Detection

- Định nghĩa intent bằng keyword
- Ưu điểm: đơn giản, dễ kiểm soát
- Nhược điểm: kém linh hoạt
- Ví dụ về luật:
 1. Nếu câu chứa từ khóa “xin chào”, “chào bạn” → intent: Chào hỏi
 2. Nếu câu chứa từ khóa “đặt vé”, “mua vé”, “vé đi” → intent: Đặt vé
 3. Nếu câu chứa từ khóa “thời tiết”, “trời hôm nay” → intent: Tra cứu thời tiết
 4. Nếu không khớp keyword nào → intent: Không xác định

Machine Learning Intent Detection

- Vector hóa câu dựa trên các kỹ thuật như: Bag of Words (BoW), TF-IDF, Word Embedding (word2vec), Sentence Embedding (BERT)
- Mô hình phân loại: SVM, Random Forest, Logistic Regression, Naive Bayes
- Cần dữ liệu gán nhãn

Các bộ dữ liệu cho Intent Detection

Bộ dữ liệu	Số intent	Ngôn ngữ	Lĩnh vực	Số mẫu
ATIS	18+	Tiếng Anh	Du lịch, vé máy bay	~6,000
SNIPS	7	Tiếng Anh	Trợ lý ảo	~14,000
CLINC150	150	Tiếng Anh	Đa lĩnh vực	22,500
BANKING77	77	Tiếng Anh	Ngân hàng	13,000
Massive	60+	Đa ngôn ngữ	Đa lĩnh vực	1 triệu+
Zalo AI 2020	7	Tiếng Việt	Đa lĩnh vực	16,000

Deep Learning Intent Detection

- Dùng RNN, LSTM, GRU
- Mô hình BERT, PhoBERT
- Cho kết quả tốt hơn ML truyền thống

Các vấn đề với xác định intent

Xử lý câu phức	Tư vấn giúp mình máy gaming khoảng 25 đến 30 triệu, ưu tiên card RTX và màn hình 144Hz nhé!
Xử lý câu có từ viết tắt nhưng tùy trường hợp lại có ý nghĩa khác nhau	Mình muốn dk mua trả góp con Asus TUF 15
	Cho mình hỏi dk trả góp bên shop là gì vậy?
Câu hỏi có nhiều giá trị của cùng một loại entity	Shop còn laptop Asus, Dell với Lenovo tầm 20 đến 30 triệu không?
	Máy này bảo hành 12 tháng hay 24 tháng vậy shop?
Câu hỏi có 2 entity cùng loại nhưng ý hỏi trong câu chỉ có 1 entity chính	Hiện tại mình mua trả góp 12 tháng, giờ muốn chuyển sang 24 tháng có được không?
	Máy mình đang chạy SSD 256GB, giờ muốn nâng lên 512GB được không?

Các vấn đề với xác định intent

Câu hỏi ngắn quăng	Máy chơi game tầm 25 triệu có mẫu nào đẹp không shop?
Câu dài, nhiều thuộc tính	Mình muốn tìm một con laptop khoảng 20 triệu, RAM 20GB hoặc hơn, SSD 100GB chắc không đủ rồi nên phải ít nhất 512GB, pin cũng khoảng 20 tiếng thì càng tốt, nặng tầm 2kg đổ lại.
Mô hình học máy nhận diện thuộc tính của thực thể	Các thuộc tính: số phút gọi nội mạng, số phút gọi ngoại mạng, số lượng sms, giá cước, dung lượng data, chu kỳ (ngày, tuần, tháng) Ví dụ câu hỏi: +kiểm tra số thuê bao của tôi đăng ký gói 100.000 đồng tháng được 6000 phút và 2gb 5g có được không ạ + Anh chị kiểm tra xem số điện thoại của em 0123456789 có gói cước nào đăng ký internet 1 tháng mà 1 ngày có 5g tốc độ cao /ngày không ạ
Câu hỏi nhiều intent	Shop cho mình hỏi con Asus TUF A15 còn hàng không, nếu có thì giá bao nhiêu, với lại trả góp 0% lãi suất trong 12 tháng được không?

3. Nhận dạng thực thể

- Mục tiêu: **trích xuất thông tin** từ câu nói của User và điền vào các **slot** (trường dữ liệu)

- Ví dụ:

*I want to fly to **San Francisco** on **Monday** please*

*Output: Destination: **San Francisco***

*Depart-time: **Monday***

- Yêu cầu: Cần dữ liệu huấn luyện (với tập nhãn **BIO**) và thuật toán học máy hoặc học sâu nhằm trích xuất thông tin (NER) hiệu quả

0	0		0	0	0	B-DES	I-DES		0	B-DEPTIME	I-DEPTIME	0																																								
I	w	a	n	t		f	l	y		t	o		S	a	n		F	r	a	n	c	i	s	c	o		o	n		M	o	n	d	a	y		a	f	t	e	r	n	o	o	n		p	l	e	a	s	e

- Hậu xử lý nhằm xác định các từ đồng nghĩa, vd "SFO" và San Francisco

- Tên gọi: named entity recognition/slot filling
- Vai trò:
 - Cung cấp dữ liệu cho chatbot xử lý
 - Hoàn thiện yêu cầu người dùng
- Ví dụ:
 - Tôi muốn đặt vé đi Đà Nẵng lúc 7 giờ sáng
O O O O O B-LOC I-LOC O B-TIME I-TIME I-TIME
Intent: đặt vé

- Rule-based
- Machine Learning (CRF, SVM):
 - Xác định tập đặc trưng (thủ công)
 - Huấn luyện mô hình dựa trên tập đặc trưng để gán nhãn cho từ
- Deep Learning (BiLSTM, BERT + CRF)
 - Tự động sinh vector đặc trưng dựa trên các vector embedding đầu vào
 - Huấn luyện mô hình dựa trên các vector đặc trưng để gán nhãn cho từ

Rule: TheGazOrganization

Priority: 50

// Matches “The <in list of company names>”

({Part of speech = DT | Part of speech = RB} {DictionaryLookup = organization}) → Organization

Rule: LocOrganization

Priority: 50

// Matches “London Police”

({DictionaryLookup = location | DictionaryLookup = country} {DictionaryLookup = organization} {DictionaryLookup = organization}?) → Organization

Rule: INOrgXandY

Priority: 200

// Matches “in Bradford & Bingley”, or “in Bradford & Bingley Ltd”

({Token string = “in”})

({Part of speech = NNP}+ {Token string = “&”} {Orthography type = upperInitial}+ {DictionaryLookup = organization end}?) :orgName → Organization=:orgName

Rule: OrgDept


Priority: 25

// Matches “Department of Pure Mathematics and Physics”

({Token.string = “Department”} {Token.string = “of”} {Orthography type = upperInitial}+ ({Token.string = “and”} {Orthography type = upperInitial}+)?) → Organization


- Hôm nay, chị **Nguyễn Chi Mai** đi thành phố **Hồ Chí Minh**
- Ông **Võ Nguyên Giáp**
- Công ty **TNHH** nhà đất **Đại Nam**, **Hà Nội**
- Đường **Tạ Quang Bửu**
- **Andrew Grove** là một giám đốc công ty **Vinamilk**, công ty sữa lớn nhất **Việt Nam**, được thành lập năm 1976.

NER sử dụng biLSTM + CRF




- Experiments on VLSP2016, performance F1=88.59%

Học biểu diễn mức ký tự




NER sử dụng biLSTM + CRF



Nguyen et al. "Neural sequence labeling for Vietnamse POS tagging and NER". RIVF 2019

Học biểu diễn ký tự



Char-level representation

Đánh giá kết quả


- **Biểu diễn từ loại:** Biểu diễn one-hot
- **Biểu diễn cụm:** Biểu diễn one-hot

Method	P	R	F1	F1 (w.o char)
Feature-rich CRFs [25]	93.87	93.99	93.93	-
NNVLP [7]	92.76	93.07	92.91	-
BiLSTM-CRFs	90.97	87.52	89.21	76.43
BiLSTM-CRFs + POS	90.90	90.39	90.64	86.06
BiLSTM-CRFs + Chunk	95.24	92.16	93.67	87.13
BiLSTM-CRFs + POS + Chunk	95.44	94.33	94.88	91.36

BiLSTM-CRFs sử dụng thêm các thông tin PoS và phân cụm

BiLSTM-CRFs không kết hợp biểu diễn mức kí tự

NER sử dụng BERT + Softmax




Các bộ dữ liệu tiếng Anh cho NER

Bộ dữ liệu	Tập nhãn	Số mẫu train-test	Nguồn dữ liệu
CoNLL-2003	PER, LOC, ORG, MISC	14,987 - 3,684	Reuters news (Anh)
OntoNotes 5.0	18 loại: PERSON, ORG, GPE, DATE, TIME, v.v.	59,924 - 8,262	Tin tức, hội thoại, blog, talk show
WNUT-17	corporation, creative-work, group, location, person, product (6)	3,394 - 1,287	Mạng xã hội, blog
ACE 2005	PER, ORG, GPE, LOC, FAC, VEH, WEA (7)	~700 tài liệu	Tin tức, email, thoại thoại, blog
WikiANN (en)	PER, LOC, ORG	20,000 - 10,000	Wikipedia (tự động gán nhãn)

Các bộ dữ liệu tiếng Việt cho NER

Tên bộ dữ liệu	Tập nhãn	Số mẫu train - test	Nguồn dữ liệu
VLSP 2016 NER	Per, Loc, Org, Misc	16,858 - 2,381	báo chí
VLSP 2018 NER	Per, Loc, Org, Misc	~20,000 - ~2,000	báo chí
UIT-ViNERT	Per, Org, Loc, Misc, Date, Time, Money, Percent, Fac, Event, Work_Of_Art	16,861 - 2,359 (Dev: 2,353)	báo chí
PhoNER_COVID 19	Per, Loc, Org, Misc, Date, Time, Event, Product, Disease	5,000 câu	Y tế, COVID-19, báo chí
ViNewsNER	Per, Loc, Org, Misc, Date, Time, Event, Product, Work_Of_Art	12,000 - 1,500 (Dev: 1,500)	báo chí
ViHealthNER	Body, Symptom, Disease, Drug, Treatment	4,000 đoạn văn bản y tế	Y tế

Joint Intent Detection and Slot Filling (JointIDSF)



Dao, M., Tinh Hung Truong and Dat Quoc Nguyen. "Intent detection and slot filling for Vietnamese." *Pacific* 2022.

Joint Intent Detection and Slot Filling (JointIDSF)

- [CLS] vector được dùng để dự đoán intent.
- Dùng phân phối xác suất các intent (softmax output), tạo một soft intent embedding bằng cách nhân xác suất với vector embedding của từng intent → kết hợp lại thành một vector đại diện cho intent.
- Sử dụng attention giữa soft intent embedding này với từng token embedding để điều chỉnh lại các token vector → slot decoder sẽ nhận vector đã được attention này.
- Các vector token để dự đoán slot cho từng token.
- Slot decoder dùng CRF để xác định nhãn

Model	Intent Acc.	Slot F1	Sent. Acc.
Our JointIDSF _{PhoBERT} encoder	98.45	97.03	89.55

Dao, M., Thanh Hung Truong and Dat Quoc Nguyen. Intent detection and slot filling for Vietnamese. *Paclic 2022*.

4. Phân tích cảm xúc trong hội thoại

- Phân tích cảm xúc cho từng câu
 - Vd: Chán thật, mình đợi lâu quá.
- Phân tích cảm xúc toàn hội thoại
 - Vd: Gán nhãn (+), (-) cho 1 đoạn hội thoại 10 câu
- Phân tích cảm xúc theo khía cạnh
 - Vd: Phim hay nhưng âm thanh dở
- Phân tích cảm xúc theo đối tượng
 - Vd: Trong mấy bạn nhân viên ở đó thì chỉ có bạn Tâm là ok thôi, các bạn khác tệ lắm.
- Phát hiện sự thay đổi cảm xúc
 - Vd: Ban đầu mình thích... nhưng sau đó thất vọng
- Phân tích cảm xúc theo từng người nói
 - Vd: A: “Dịch vụ tốt lắm.” → Positive (A)
 - B: “Mình không thấy vậy đâu.” → Negative (B)

Các cách tiếp cận

- Dựa trên luật: dùng luật và từ điển cảm xúc
- Dựa trên học máy: dùng BoW, TF-IDF, từ điển cảm xúc,... với SVM, Naive Bayes
- Dựa trên học sâu: CNN, LSTM, BiLSTM+Attention, BERT, PhoBERT, RoBERTa
- Zero-shot/Few-shot: dùng GPT, T5, LLaMA với prompt

5. Các kỹ thuật nâng cao chất lượng chatbot với LLM

- Fine-tuning & Instruction-tuning
- Prompt Engineering
- Context-aware & RAG
- NER, Intent & Knowledge-enhanced
- Adapter-based & Data Augmentation

Fine-tuning & Instruction-tuning

Fine-tuning

- Điều chỉnh mô hình cho một tác vụ cụ thể.
- Dữ liệu mẫu: cặp input – output
 - Vd: {"input": "The movie was fantastic!", "label": "positive"}
- Mô hình LLM nhỏ - vừa (100M → 7B params).
 - Vd BERT-base (110M), LLaMA-7B

Instruction-tuning

- Điều chỉnh mô hình để hiểu và làm theo chỉ dẫn, xử lý đa tác vụ qua prompt.
- Dữ liệu mẫu: cặp instruction – output
 - Vd: {"instruction": "Sentiment analysis: The movie was fantastic!", "label": "positive"}
- Thường dùng mô hình lớn (7B → 70B+ params)
 - Vd: FLAN-T5-XXL (11B), LLaMA-13B, 30B, 70B

Fine-tuning & Instruction-tuning

Fine-tuning

- Chi phí thấp, ít tài nguyên
- Mô hình nhỏ vẫn đạt hiệu quả tốt với tác vụ cụ thể
- Ưu: nhanh, hiệu quả cho tác vụ cụ thể
- Nhược: phải train riêng cho từng tác vụ

Instruction-tuning

- Chi phí cao, tốn nhiều GPU
- Mô hình càng lớn càng hiểu tốt chỉ dẫn
- Ưu: đa năng, chỉ cần 1 model cho nhiều tác vụ
- Nhược: cần dữ liệu chỉ dẫn đa dạng, tốn tài nguyên

Các bộ dữ liệu hỗ trợ fine-tuning/ Instruction-tuning

- **SQuAD**: 100,000+ câu hỏi và câu trả lời (SQuAD 1.1)
- **QuAC**: 100,000+ câu hỏi và câu trả lời trong các cuộc trò chuyện
- **Natural Questions**: Khoảng 300,000 câu hỏi từ người dùng với đoạn văn dài để trả lời
- **DSTC**: 60,000+ lượt trò chuyện từ nhiều bài toán khác nhau trong lĩnh vực đối thoại
- **TriviaQA**: Khoảng 650,000 câu hỏi và câu trả lời
- **CoQA**: Khoảng 127,000 câu hỏi và câu trả lời trong các cuộc trò chuyện đa lượt
- **TREC**: 6,000+ câu hỏi phân loại thành 6 nhãn
- **Open-Domain QA**: WikiQA (2,100 câu hỏi) và WebQuestions (6,000 câu hỏi)
- **MultiWOZ**: 10,000+ cuộc trò chuyện với hơn 100,000 lượt trò chuyện

- Prompt Engineering có thể làm gì:
 - Thiết kế câu lệnh mẫu cho từng tác vụ.
 - Hướng dẫn chatbot phân tích, dự đoán ý định và thực thể
 - Điều chỉnh phong cách và định dạng câu trả lời.
 - Tối ưu hóa luồng hội thoại đa lượt.
- Các kỹ thuật: Zero-shot, Few-shot, Chain-of-thought

Ví dụ về Prompt Nhận diện ý định

Bạn là một hệ thống nhận diện ý định cho chatbot bán quần áo online.

Nhiệm vụ của bạn: Dựa trên nội dung tin nhắn của khách hàng, hãy xác định **duy nhất một** trong các ý định sau:

- **OrderProduct**: Đặt mua sản phẩm
- **AskPrice**: Hỏi giá sản phẩm
- **AskAvailability**: Hỏi tình trạng còn hàng
- **AskDelivery**: Hỏi về giao hàng, phí ship
- **AskReturnPolicy**: Hỏi về đổi/trả hàng
- **AskPromotion**: Hỏi về chương trình khuyến mãi
- **CancelOrder**: Yêu cầu hủy đơn hàng
- **Other**: Khác (nếu không thuộc các ý định trên)

Đầu ra mong muốn: Chỉ trả về tên ý định (ví dụ: OrderProduct hoặc AskPrice)

Câu: Áo khoác jean màu đen còn size M không shop?

➤ **AskAvailability**

Ví dụ về Prompt Nhận dạng thực thể

Bạn là một hệ thống nhận diện thực thể cho chatbot bán hàng online.

Nhiệm vụ của bạn: Xác định và trích xuất các thực thể sau từ câu hỏi hoặc yêu cầu của khách hàng:

- **Product:** tên sản phẩm
- **Quantity:** số lượng sản phẩm
- **Color:** màu sắc sản phẩm
- **Size:** kích cỡ sản phẩm
- **Address:** địa chỉ giao hàng
- **PhoneNumber:** số điện thoại liên hệ
- **PaymentMethod:** phương thức thanh toán

Nếu không có thực thể nào, trả về giá trị rỗng cho thực thể đó.

- Đầu ra mong muốn: Danh sách các thực thể và giá trị tương ứng dưới dạng JSON.
- Câu: 'Tôi muốn mua 2 chiếc áo thun màu trắng size M.'

➤ **Product: áo thun, Quantity: 2, Color: trắng, Size: M**

Ví dụ về Prompt sinh câu trả lời

Bạn là một chatbot bán quần áo chuyên nghiệp.

Nhiệm vụ của bạn: Dựa trên câu hỏi hoặc yêu cầu của khách hàng, hãy tạo một câu trả lời tự nhiên, lịch sự và phù hợp với ngữ cảnh mua bán quần áo.

Quy tắc:

- Nếu khách hỏi về sản phẩm, mô tả ngắn gọn về sản phẩm (ví dụ: chất liệu, màu sắc, size có sẵn...).
- Nếu khách hỏi giá, hãy báo giá một cách rõ ràng.
- Nếu khách hỏi còn hàng hay không, xác nhận tình trạng còn/hết hàng.
- Nếu khách hỏi về chính sách giao hàng, đổi trả, hỗ trợ họ bằng thông tin ngắn gọn.
- Nếu khách đặt hàng, xác nhận lại đơn hàng và xin thông tin giao hàng (số điện thoại, địa chỉ).
- Luôn giữ giọng điệu thân thiện, nhiệt tình, không dùng từ ngữ thô lỗ hay cứng nhắc.
- Đầu ra mong muốn: Một câu trả lời hoàn chỉnh, tự nhiên như một nhân viên bán hàng thực thụ.
- Câu: Shop còn áo sơ mi nam màu trắng size M không?

➤ **Dạ shop còn áo sơ mi nam màu trắng size M ạ! Anh/chị muốn mình giữ đơn và giao hàng ngay hôm nay không ạ?**

Ví dụ về Prompt cho Hội thoại đa lượt

Bạn là một chatbot hỗ trợ đặt bàn tại nhà hàng.

Nhiệm vụ của bạn:

- Tiếp tục hội thoại một cách tự nhiên, lịch sự, ngắn gọn.
- Mục tiêu là thu thập đầy đủ thông tin đặt bàn, bao gồm:
 - Thời gian (giờ đặt), số lượng người (bao nhiêu người), tên khách hàng, số điện thoại liên hệ, yêu cầu đặc biệt (nếu có, ví dụ: phòng riêng, bàn gần cửa sổ, ăn chay,...)

Quy tắc:

- Chỉ hỏi tiếp những thông tin còn thiếu.
- Khi hỏi, hãy dùng câu văn tự nhiên, dễ chịu, tránh cứng nhắc.
- Sau khi thu thập đủ thông tin, tóm tắt lại toàn bộ yêu cầu đặt bàn và hỏi khách xác nhận.

Tiếp tục hội thoại dưới đây một cách tự nhiên:

- User: 'Tôi muốn đặt bàn vào tối nay.'
- Chatbot: 'Bạn muốn đặt vào mấy giờ?'
- User: '7 giờ.'

➤ **Cảm ơn bạn, bạn muốn đặt cho mấy người ạ?**

Các dạng prompt

- Zero-shot
 - Xác định ý định của câu sau và trả lời bằng một trong các nhãn: [Chào hỏi, Hỏi thông tin, Khiếu nại]: 'Tôi muốn biết thời gian làm việc của cửa hàng'
- One-shot
 - 'Xin chào bạn' → Chào hỏi.
 - Câu: 'Tôi muốn biết thời gian làm việc của cửa hàng' → ?
- Few-shot
 - 'Xin chào bạn' → Chào hỏi.
 - 'Giá sản phẩm này là bao nhiêu?' → Hỏi thông tin.
 - Câu: 'Tôi muốn biết thời gian làm việc của cửa hàng' → ?


- Ghi nhớ và **hiểu** nội dung các lượt hội thoại trước, nhằm phản hồi phù hợp theo dòng hội thoại.
- Các phương pháp:
 - **Sử dụng session history ghi nhớ toàn bộ hội thoại.**
 - Lưu mỗi lượt hỏi/đáp như một mảng hoặc chuỗi.
 - Ví dụ: ['User: Mở tài khoản', 'Bot: Bạn muốn tài khoản cá nhân hay doanh nghiệp?']...
 - Sử dụng sliding window để giới hạn độ dài prompt.
 - **Tóm tắt ngữ cảnh:**
 - Giảm độ dài input nhưng vẫn giữ thông tin cốt lõi.
 - Ứng dụng mô hình tóm tắt như T5, BART hoặc LLM.
 - **Tracking trạng thái hội thoại (dialogue state tracking – DST)**
 - Lưu lại các slot đã được điền.
 - Ví dụ: intent='đặt vé', slot1='Sài Gòn', slot2='Hà Nội'...
 - DST giúp phản hồi chính xác theo trạng thái hiện tại.

- **Document Store:** Cơ sở dữ liệu chứa tri thức (wiki, tài liệu, nội bộ...).
- **Retriever:** Tìm các đoạn văn liên quan từ CSTT
- **Generator:** Tạo câu trả lời dựa trên thông tin truy xuất được.
 - Sử dụng LLM như GPT, LLaMA, T5...
 - Prompt gồm cả câu hỏi và đoạn văn truy xuất.
 - Có thể fine-tune để sinh câu trả lời ngắn gọn, chính xác hơn.
- Rất hữu ích trong các lĩnh vực như chăm sóc khách hàng, trợ lý ảo, giáo dục.

Adapter-based

- Adapter là phương pháp fine-tuning hiệu quả và nhẹ.
- Chỉ huấn luyện một số layer nhỏ được chèn thêm vào mô hình.
- Giữ nguyên trọng số mô hình gốc – tiết kiệm bộ nhớ và thời gian huấn luyện.
- Các thư viện hỗ trợ
 - HuggingFace PEFT (Parameter-Efficient Fine-Tuning).
 - AdapterHub: nhiều adapter có sẵn cho các mô hình NLP.
 - LoRA (Low Rank Adapter): phiên bản tối ưu hơn của Adapter.

Finetuning LLMs Efficiently with Adapters



Comparison of the regular transformer blocks used in various LLMs and a transformer block modified via the adapter layers.

<https://magazine.sebastianraschka.com/p/finetuning-llms-with-adapters>

Finetuning LLMs Efficiently with Adapters



```
1  def transformer_block_with_adapter(x):
2      residual = x
3      x = self_attention(x)
4      x = AdapterLayers(x)  # adapter
5      x = LayerNorm(x + residual)
6      residual = x
7      x = FullyConnectedLayers(x)
8      x = AdapterLayers(x)  # adapter
9      x = LayerNorm(x + residual)
10     return x
```

Data Augmentation

- Data Augmentation là kỹ thuật tạo dữ liệu huấn luyện mới từ dữ liệu có sẵn.
- Giúp tăng số lượng và tính đa dạng của tập dữ liệu hội thoại.
- Quan trọng trong các hệ thống GenAI khi dữ liệu thực tế hạn chế.
- Lợi ích:
 - Giảm overfitting.
 - Tăng khả năng tổng quát hóa của mô hình chatbot.
 - Mô phỏng được nhiều tình huống thực tế hơn.

Các phương pháp tăng cường dữ liệu phổ biến

- **Paraphrasing:** Dùng mô hình LLM hoặc công cụ NLP để viết lại câu hỏi/trả lời.
- **Back-translation:** Dịch câu sang ngôn ngữ khác rồi dịch ngược lại.
- **Template-based generation:** Tạo mẫu câu cố định với chỗ trống có thể điền giá trị
 - Ví dụ: "Tôi muốn [hành động] [dịch vụ] lúc [thời gian]".
- **Entity swapping:** Thay thế các thực thể trong câu hỏi bằng thực thể khác.
- **Synthetic generation** bằng LLM:
 - Ví dụ prompt: "Tạo đoạn hội thoại giữa khách và nhân viên khách sạn".